

Propozycje projektów końcowych
Wizja komputerowa, dane syntetyczne i testowanie architektur

Projekty dla studentów V roku / ostatniego semestru. Realizacja w parach dwuosobowych.

Zasady ogólne

Każdy projekt jest realizowany przez dokładnie dwie osoby. Temat ma prowadzić do kompletnego, mierzalnego eksperymentu z użyciem modeli wizyjnych: klasyfikacji, detekcji, segmentacji, pseudoetykietowania, samonadzorowanego uczenia reprezentacji albo analizy luki domenowej. Projekty mogą mocniej akcentować generowanie danych syntetycznych albo testowanie architektur, ale każdy projekt musi kończyć się wynikami ilościowymi i jakościowymi.

- Każda para musi udostępnić publiczne lub dostępne dla prowadzącego repozytorium GitHub z kodem, konfiguracjami, instrukcją uruchomienia, skryptami przygotowania danych i wynikami eksperymentów.
- Każda para musi przygotować dokument wynikowy, najlepiej w formacie PDF lub Google Docs, opisujący cel, dane, metody, architektury, eksperymenty, wyniki, wizualizacje, błędy i ograniczenia.
- Link do repozytorium oraz link do dokumentu wynikowego muszą zostać wpisane do arkusza Google Sheets: [arkusz projektów](#).
- W arkuszu powinny znaleźć się co najmniej: numer projektu, imiona i nazwiska studentów, link do repozytorium, link do raportu, link do danych/artefaktów/modeli, krótki opis finalnego wariantu eksperymentu oraz status projektu.
- Zbiory danych wskazane poniżej są publicznie dostępne lub powszechnie używane w badaniach. Przed użyciem należy sprawdzić i respektować licencję konkretnego zbioru, obrazu i adnotacji; nie wszystkie zbiory są stricte CC0/public domain.

Minimalny zakres wyników

- Dla lżejszych projektów klasyfikacyjnych lub segmentacyjnych oczekiwane jest około 15-30 sensownych konfiguracji lub wariantów eksperymentalnych.
- Dla cięższych projektów detekcyjnych oczekiwane jest około 8-15 konfiguracji, ale z pełniejszą analizą kosztu obliczeniowego, błędów i transferu domenowego.
- Każdy projekt musi zawierać punkt odniesienia, warianty porównawcze, tabele metryk, wykresy, wizualizacje wyników, przykłady błędów oraz interpretowalność: Grad-CAM, mapy uwagi, aktywacje, filtry lub osadzenia.
- Raport powinien mieć strukturę krótkiego artykułu: wstęp i pytanie badawcze, przegląd literatury, opis danych, metoda, protokół eksperymentów, wyniki, analiza jakościowa, ograniczenia, wnioski i instrukcja reprodukcji.

Skrót projektów

Nr	Temat	Typ projektu	Główne zadanie
1	Augmentacja generatywna dla klasyfikacji obrazów przy małej liczbie danych	dane syntetyczne / generatywna sztuczna inteligencja	klasyfikacja obrazów
2	Detekcja obiektów z danych syntetycznych wygenerowanych w Blender Geometry Nodes	syntetyczne dane / Blender	detekcja obiektów
3	Losowa zmienność domeny (domain randomization) dla segmentacji semantycznej lub instancyjnej	syntetyczne dane / segmentacja	segmentacja semantyczna lub instancyjna
4	Detekcja obiektów na zdjęciach lotniczych: porównanie architektur pod przesunięciem domeny	testowanie architektur / transfer syntetyczne-rzeczywiste	detekcja małych obiektów
5	Transformery wizyjne kontra ConvNety przy zmianie pogody i punktu widzenia	testowanie architektur / odporność modeli	segmentacja semantyczna scen drogowych
6	Selekcja syntetycznych widoków obiektu z użyciem dopasowań geometrycznych	syntetyczne dane / analiza domeny	detekcja, segmentacja lub uproszczona estymacja pozy / punktów kluczowych
7	Co sieci naprawdę uczą się z danych syntetycznych? Aktywacje, filtry i skróty decyzyjne	interpretowalność / testowanie architektur	klasyfikacja lub detekcja
8	Pseudo-etykiety z SAM 2 kontra perfekcyjne maski syntetyczne	segmentacja / pseudoetykietowanie / syntetyczne dane	segmentacja semantyczna lub instancyjna
9	Samonadzorowane pretrenowanie na danych syntetycznych	syntetyczne dane / uczenie samonadzorowane	klasyfikacja, detekcja lub segmentacja po transferze
10	Ranking wariantów danych syntetycznych przed pełnym treningiem modelu	podejście skoncentrowane na danych (data-centric AI) / analiza luki domenowej	klasyfikacja, detekcja, segmentacja lub uproszczona poza

Propozycje projektów

1. Augmentacja generatywna dla klasyfikacji obrazów przy małej liczbie danych

Kierunek: dane syntetyczne / generatywna sztuczna inteligencja

Zadanie wizyjne: klasyfikacja obrazów

Publicznie dostępne zbiory danych: Open Images, COCO, EuroSAT, Oxford-IIIT Pets

Pytanie badawcze: Czy obrazy generowane przez modele generatywne realnie poprawiają klasyfikację przy małej liczbie danych, czy tylko zwiększają liczbę wizualnie przekonujących, ale mało użytecznych próbek?

Opis projektu: Para wybiera 5-20 klas i przygotowuje warianty treningowe: tylko dane rzeczywiste, klasyczna augmentacja, dane generowane z prostych promptów, dane

generowane z personalizacją klasy lub obiektu oraz dane generowane po filtrowaniu jakościowym. Projekt powinien sprawdzać nie tylko końcową dokładność, ale także to, czy wygenerowane próbki zwiększają różnorodność cech i zmniejszają błędy między podobnymi klasami.

Modele i metody do przetestowania:

- ResNet-18/50
- ConvNeXt-Tiny lub ConvNeXt V2
- ViT-Tiny / DeiT
- DINOv2 jako ekstraktor cech z prostą głowicą liniową

Wymagane eksperymenty:

- porównanie tylko dane rzeczywiste, tylko klasyczna augmentacja, tylko dane generowane, dane rzeczywiste + dane generowane i dane rzeczywiste + przefiltrowane dane generowane
- minimum 3 ziarna losowe dla głównych konfiguracji
- sprawdzenie wpływu liczby wygenerowanych obrazów na wynik
- porównanie metod filtrowania na podstawie osadzeń, CLIP/DINO lub CLER-podobnej metryki

Wymagane wyniki i analiza:

- dokładność, zbalansowana dokładność i makro-F1
- macierz pomyłek i analiza najczęstszych błędów
- Grad-CAM lub mapy uwagi typu attention rollout dla przykładów sukcesu i porażki
- wykres zależności: liczba danych syntetycznych kontra jakość na walidacji rzeczywistej

Linki: [Open Images](#); [COCO](#); [EuroSAT](#); [Oxford-IIIT Pets](#); [GenBench / CLER](#); [CLIP](#); [DINOv2](#); [ConvNeXt V2](#)

2. Detekcja obiektów z danych syntetycznych wygenerowanych w Blender Geometry Nodes

Kierunek: syntetyczne dane / Blender

Zadanie wizyjne: detekcja obiektów

Publicznie dostępne zbiory danych: własny zbiór syntetyczny Blender, mały rzeczywisty zbiór walidacyjny, COCO, Open Images

Pytanie badawcze: Które decyzje renderowania syntetycznego — tło, światło, materiał, pozycja kamery, rozmycie, przesłonięcia — najbardziej wpływają na transfer detektora do rzeczywistych zdjęć?

Opis projektu: Projekt bezpośrednio wykorzystuje warsztat z Blender Geometry Nodes. Para generuje obrazy syntetyczne w formacie COCO z automatycznymi ramkami ograniczającymi. Obiektem może być radio, produkt, narzędzie, element wyposażenia lub zestaw 2-5 obiektów. Trzeba przygotować mały rzeczywisty zbiór testowy, ręcznie oznaczyć ramki ograniczające i sprawdzić, czy model trenowany na syntetykach rozpoznaje obiekt w rzeczywistych warunkach.

Modele i metody do przetestowania:

- YOLOv10
- RT-DETR/RT-DETRv2
- D-FINE
- Faster R-CNN jako klasyczny punkt odniesienia

Wymagane eksperymenty:

- tylko dane syntetyczne, tylko dane rzeczywiste, dane syntetyczne + dane rzeczywiste, pretrenowanie na danych syntetycznych + dostrajanie na danych rzeczywistych
- warianty renderingu: czyste tło, losowe tła, losowe światło, losowe materiały, silne przesłonięcia
- porównanie małego i dużego detektora
- pomiar czasu inferencji i pamięci GPU

Wymagane wyniki i analiza:

- mAP@50 i mAP@50:95
- krzywe precyzja-czułość
- przykłady fałszywe alarmy i pominięcia
- Grad-CAM dla detekcji lub wizualizacja aktywacji map cech
- tabela, które parametry generowania poprawiają transfer

Linki: [YOLOv10](#); [RT-DETRv2](#); [D-FINE](#); [Detectron2](#); [Unity SynthDet](#); [COCO](#); [Open Images](#)

3. Losowa zmienność domeny (domain randomization) dla segmentacji semantycznej lub instancyjnej

Kierunek: syntetyczne dane / segmentacja

Zadanie wizyjne: segmentacja semantyczna lub instancyjna

Publicznie dostępne zbiory danych: własne maski z Blendera, COCO, ADE20K, Oxford-IIIT Pets

Pytanie badawcze: Co bardziej pomaga w transferze segmentacji z danych syntetycznych do rzeczywistych: fotorealizm, losowość tekstur, losowość oświetlenia, złożone tło czy kontrolowana geometria?

Opis projektu: Para generuje w Blenderze obrazy RGB oraz maski segmentacyjne. Następnie tworzy kilka kontrolowanych wariantów danych syntetycznych: realistyczne materiały, losowe materiały, jednolite tło, tło z publicznych zdjęć, losowe światła i losowe pozycje kamery. Celem jest wykazanie, które źródła różnorodności poprawiają generalizację na danych rzeczywistych.

Modele i metody do przetestowania:

- U-Net lub DeepLabV3+ jako punkt odniesienia
- Mask R-CNN dla segmentacji instancyjnej
- SegFormer jako wariant transformerowy
- SAM 2 jako narzędzie pomocnicze do pseudoetykiet lub porównania masek

Wymagane eksperymenty:

- co najmniej 4 warianty losowej zmienności domeny
- porównanie tylko dane syntetyczne, tylko mały zbiór rzeczywisty i wariant mieszany

- osobna ocena klas łatwych i trudnych
- badanie ablacyjne dla oświetlenia, tekstur, tła i geometrii

Wymagane wyniki i analiza:

- mIoU, Dice/F1 lub mask AP
- F-score granic dla jakości granic masek
- wizualizacje masek na 30-50 przykładach
- analiza błędów: tło, granice, małe obiekty, przesłonięcia
- mapy uwagi lub Grad-CAM dla sieci segmentacyjnej

Linki: [ADE20K](#); [COCO](#); [Oxford-IIIT Pets](#); [SegFormer](#); [SAM 2](#); [Detectron2](#)

4. Detekcja obiektów na zdjęciach lotniczych: porównanie architektur pod przesunięciem domeny

Kierunek: testowanie architektur / transfer syntetyczne-rzeczywiste

Zadanie wizyjne: detekcja małych obiektów

Publicznie dostępne zbiory danych: RarePlanes, xView

Pytanie badawcze: Która architektura detekcyjna jest najbardziej odporna na małe obiekty, wysoką rozdzielczość i różnice między syntetycznymi a rzeczywistymi obrazami satelitarnymi?

Opis projektu: Projekt wykorzystuje zbiory obrazów lotniczych i satelitarnych. RarePlanes zawiera zarówno obrazy rzeczywiste, jak i syntetyczne samolotów, a xView pozwala przetestować detekcję wielu klas w danych overhead. Para ma porównać architektury, ale także uczciwie przeanalizować wpływ domeny i rozmiaru obiektu na metryki.

Modele i metody do przetestowania:

- YOLOv10
- RT-DETR/RT-DETRv2
- D-FINE
- Faster R-CNN / RetinaNet jako punkt odniesienia

Wymagane eksperymenty:

- tylko dane syntetyczne, tylko dane rzeczywiste, pretrenowanie na danych syntetycznych + dostrajanie na danych rzeczywistych, trening mieszany
- AP osobno dla małych, średnich i dużych obiektów
- porównanie rozmiaru wejścia, augmentacji i kafelkowania dużych zdjęć
- porównanie FPS i zużycia pamięci

Wymagane wyniki i analiza:

- mAP@50, mAP@50:95 i AP dla małych obiektów
- mapy fałszywych alarmów na obrazach z góry/satelitarnych
- ranking architektur według jakości i kosztu
- wizualizacja aktywacji modelu dla małych obiektów
- wnioski, czy nowszy model rzeczywiście wygrywa po uwzględnieniu kosztu obliczeniowego

Linki: [RarePlanes](#); [RarePlanes GitHub](#); [xView](#); [YOLOv10](#); [RT-DETRv2](#); [D-FINE](#); [Detectron2](#)

5. Transformery wizyjne kontra ConvNety przy zmianie pogody i punktu widzenia

Kierunek: testowanie architektur / odporność modeli

Zadanie wizyjne: segmentacja semantyczna scen drogowych

Publicznie dostępne zbiory danych: Virtual KITTI 2, Cityscapes

Pytanie badawcze: Czy modele transformerowe są bardziej odporne od klasycznych ConvNetów na zmianę pogody, oświetlenia i ustawienia kamery w syntetycznych oraz rzeczywistych scenach miejskich?

Opis projektu: Virtual KITTI 2 zawiera warianty syntetyczne scen drogowych, m.in. zmiany pogody, oświetlenia i kamery. Cityscapes dostarcza rzeczywiste sceny miejskie z adnotacjami segmentacyjnymi. Para powinna zbudować eksperyment transfer syntetyczne-rzeczywiste i ocenić, czy typ architektury wpływa na stabilność predykcji.

Modele i metody do przetestowania:

- DeepLabV3+ z ResNet lub ConvNeXt
- SegFormer
- DINOv2 jako sieć bazowa/ekstraktor cech
- MAE/ViT jako wariant transformerowy

Wymagane eksperymenty:

- trening na Virtual KITTI 2 i test na Cityscapes
- osobna ocena wariantów pogody i kamery
- porównanie ConvNet kontra Transformer przy tej samej liczbie epok
- ablation dla augmentacji koloru i geometrii

Wymagane wyniki i analiza:

- mIoU globalnie i per klasa
- spadek jakości między pogodami jako metryka robustności
- mapy uwagi dla transformerów i Grad-CAM dla ConvNetów
- analiza klas trudnych: droga, chodnik, pojazdy, piesi, roślinność
- wykres jakości kontra liczba parametrów/FLOPs

Linki: [Virtual KITTI 2](#); [Cityscapes](#); [SegFormer](#); [DINOv2](#); [ConvNeXt V2](#); [MAE](#)

6. Selekcja syntetycznych widoków obiektu z użyciem dopasowań geometrycznych

Kierunek: syntetyczne dane / analiza domeny

Zadanie wizyjne: detekcja, segmentacja lub uproszczona estymacja pozy / punktów kluczowych

Publicznie dostępne zbiory danych: T-LESS / BOP, własne renderzy obiektów z Blendera

Pytanie badawcze: Czy można wybrać lepsze obrazy syntetyczne przed treningiem modelu, mierząc podobieństwo wyglądu i spójność geometryczną między obrazami syntetycznymi a rzeczywistymi?

Opis projektu: Projekt jest inspirowany problemem 6D pose, ale nie musi implementować pełnej estymacji 6D. Para może wybrać detekcję, maski lub punkty kluczowe. Kluczowe jest wygenerowanie wielu syntetycznych widoków obiektu, a następnie ranking lub filtrowanie tych widoków na podstawie dopasowań geometrycznych i osadzeń wizualnych. Potem należy sprawdzić, czy model trenowany na przefiltrowanych syntetykach działa lepiej.

Modele i metody do przetestowania:

- YOLOv10 lub RT-DETR do detekcji
- Mask R-CNN lub SAM 2 do masek
- prosta sieć do punktów kluczowych
- MAST3R, LightGlue/SuperPoint albo LoFTR jako narzędzia dopasowania

Wymagane eksperymenty:

- wszystkie dane syntetyczne kontra losowy podzbiór kontra podzbiór filtrowany geometrycznie kontra podzbiór filtrowany wyglądem
- ranking wariantów syntetycznych przed treningiem
- porównanie liczby syntetycznych widoków przy stałym budżecie treningowym
- wizualizacja par rzeczywiste-syntetyczne z dobrym i złym dopasowaniem

Wymagane wyniki i analiza:

- AP/mIoU albo błąd punktów kluczowych
- liczba inlierów geometrycznych lub wynik dopasowania
- korelacja między wynikiem metryki przed treningiem a wynikiem po treningu
- przykłady dopasowań MAST3R/LightGlue/LoFTR
- wnioski, czy filtrowanie ogranicza lukę domenową

Linki: [BOP datasets](#); [T-LESS toolkit](#); [MAST3R](#); [LightGlue](#); [LoFTR](#); [YOLOv10](#); [SAM 2](#)

7. Co sieci naprawdę uczą się z danych syntetycznych? Aktywacje, filtry i skróty decyzyjne

Kierunek: interpretowalność / testowanie architektur

Zadanie wizyjne: klasyfikacja lub detekcja

Publicznie dostępne zbiory danych: COCO, Open Images, własny zbiór Blender, RarePlanes

Pytanie badawcze: Czy model trenowany na syntetykach uczy się obiektu, czy raczej artefaktów renderingu, tła, tekstur i innych skrótów decyzyjnych?

Opis projektu: To projekt diagnostyczny. Para trenuje ten sam model na różnych reżimach danych: tylko dane rzeczywiste, tylko dane syntetyczne, słaba randomizacja syntetyczna, silna randomizacja syntetyczna i mieszanka danych. Następnie analizuje aktywacje warstw, mapy uwagi, Grad-CAM oraz przypadki błędów. Celem jest wykrycie, kiedy syntetyki tworzą bias tła, bias tekstury lub bias kształtu.

Modele i metody do przetestowania:

- ResNet/ConvNeXt dla klasyfikacji
- YOLOv10 lub Faster R-CNN dla detekcji
- ViT/DINOv2 dla analizy uwagi

Wymagane eksperymenty:

- porównanie 4-5 reżimów danych
- analiza wrażliwości na zasłanianie fragmentów obrazu: usuwanie tła, tekstury, części obiektu
- UMAP/t-SNE osadzeń cech dla danych rzeczywistych i syntetycznych
- analiza 50 poprawnych i 50 błędnych predykcji

Wymagane wyniki i analiza:

- dokładność lub mAP
- co najmniej 50 wizualizacji Grad-CAM / mapy uwagi
- mapy filtrów lub aktywacji wybranych warstw
- ranking najczęstszych skrótów decyzyjnych
- sekcja w raporcie: kiedy syntetyki pomagają, a kiedy szkodzą

Linki: [pytorch-grad-cam](#); [DINOv2](#); [COCO](#); [Open Images](#); [RarePlanes](#); [ConvNeXt V2](#)

8. Pseudo-etykiety z SAM 2 kontra perfekcyjne maski syntetyczne

Kierunek: segmentacja / pseudoetykietowanie / syntetyczne dane

Zadanie wizyjne: segmentacja semantyczna lub instancyjna

Publicznie dostępne zbiory danych: COCO, ADE20K, Cityscapes, własny zbiór Blender + zbiór rzeczywisty

Pytanie badawcze: Czy lepiej użyć perfekcyjnych masek z Blendera, pseudoetykiet z SAM 2, czy małej liczby ręcznych etykiet rzeczywistych?

Opis projektu: Para porównuje trzy źródła masek: automatyczne maski syntetyczne, pseudoetykiety wygenerowane na rzeczywistych obrazach przez SAM 2 oraz mały zbiór ręcznie poprawionych masek. Projekt ma pokazać nie tylko wynik końcowy, ale także koszt etykietowania, poziom szumu w maskach i wpływ jakości pseudoetykiet na model uczony od zera lub dostrajany.

Modele i metody do przetestowania:

- SAM 2 jako narzędzie pseudoetykietowania
- Mask R-CNN
- DeepLabV3+
- SegFormer

Wymagane eksperymenty:

- tylko maski syntetyczne, tylko pseudoetykiety z SAM 2, tylko mały zbiór ręcznych etykiet, etykiety mieszane
- krzywe efektywności etykietowania: 10, 25, 50, 100 procent etykiet
- test odporności na szum w maskach
- porównanie czasu przygotowania danych

Wymagane wyniki i analiza:

- mIoU, Dice/F1 albo mask AP
- ocena jakości pseudoetykiet na ręcznie sprawdzonym podzbiorze
- wizualizacje nakładek masek

- tabela koszt-jakość
- wniosek, kiedy SAM 2 jest lepszy niż syntetyki, a kiedy odwrotnie

Linki: [SAM 2](#); [COCO](#); [ADE20K](#); [Cityscapes](#); [SegFormer](#); [Detectron2](#)

9. Samonadzorowane pretrenowanie na danych syntetycznych

Kierunek: syntetyczne dane / uczenie samonadzorowane

Zadanie wizyjne: klasyfikacja, detekcja lub segmentacja po transferze

Publicznie dostępne zbiory danych: duży własny korpus Blender, COCO, Open Images, ADE20K, EuroSAT

Pytanie badawcze: Czy duży zbiór syntetycznych obrazów może być użyteczny bez etykiet, jeśli wykorzystamy go do samonadzorowanego pretrenowania reprezentacji?

Opis projektu: Para generuje lub zbiera duży korpus syntetyczny bez używania etykiet do treningu SSL. Następnie pretrenuje model metodą MAE lub używa istniejących reprezentacji DINOv2/ConvNeXt V2 jako punktu odniesienia. Po pretrenowaniu model jest dostrajany na małym zbiorze rzeczywistym. Najważniejsze jest sprawdzenie, czy syntetyczne pretrenowanie poprawia transfer przy małej liczbie próbek (few-shot).

Modele i metody do przetestowania:

- MAE
- DINOv2 jako mocny punkt odniesienia
- ConvNeXt V2
- ResNet/ConvNeXt trenowany od zera

Wymagane eksperymenty:

- inicjalizacja losowa kontra pretrenowanie na ImageNet kontra pretrenowanie samonadzorowane na syntetykach
- sonda liniowa i pełne dostrajanie
- mała liczba próbek (few-shot): 1%, 5%, 10%, 25% danych rzeczywistych
- porównanie syntetyków realistycznych i mocno randomizowanych

Wymagane wyniki i analiza:

- dokładność/mAP/mIoU zależnie od zadania
- krzywe mała liczba próbek (few-shot)
- wizualizacja osadzeń UMAP/t-SNE
- wyszukiwanie najbliższych sąsiadów w przestrzeni cech
- analiza, czy syntetyki poprawiają kształt, teksturę czy tło

Linki: [MAE](#); [DINOv2](#); [ConvNeXt V2](#); [COCO](#); [Open Images](#); [ADE20K](#); [EuroSAT](#)

10. Ranking wariantów danych syntetycznych przed pełnym treningiem modelu

Kierunek: podejście skoncentrowane na danych (data-centric AI) / analiza luki domenowej

Zadanie wizyjne: klasyfikacja, detekcja, segmentacja lub uproszczona poza

Publicznie dostępne zbiory danych: Virtual KITTI 2, RarePlanes, T-LESS/BOP, własne warianty Blender, COCO/Open Images jako domena rzeczywista

Pytanie badawcze: Czy można przewidzieć, który wariant danych syntetycznych da najlepszy model, zanim wykonamy kosztowny pełny trening?

Opis projektu: Para przygotowuje kilka wariantów syntetycznego zbioru danych, np. różne tła, oświetlenie, tekstury, stopień randomizacji lub renderer. Przed pełnym treningiem liczy metryki podobieństwa wyglądu i geometrii między syntetykami a domeną rzeczywistą. Następnie trenuje modele tylko dla wybranych wariantów i sprawdza, czy ranking przed treningiem koreluje z realną jakością modelu.

Modele i metody do przetestowania:

- dowolny model adekwatny do zadania: ResNet/ViT, YOLO/RT-DETR/D-FINE, SegFormer/Mask R-CNN
- CLIP/DINO/LPIPS/FID jako metryki wyglądu
- MAST3R/LoFTR/LightGlue jako metryki geometryczne

Wymagane eksperymenty:

- minimum 5 wariantów syntetycznych
- ranking wariantów przed treningiem
- trening pełny dla 3-5 wariantów i trening skrócony dla wszystkich wariantów
- porównanie samego wyglądu, samej geometrii i fuzji obu sygnałów

Wymagane wyniki i analiza:

- tabela rankingów przed treningiem i po treningu
- Pearson i Spearman między wynikiem metryki a wynikiem zadania docelowego
- wykres kosztu: metryka przed treningiem kontra pełny trening
- przykłady par rzeczywiste-syntetyczne o wysokim i niskim wyniku metryki
- wniosek praktyczny: czy ranking oszczędza czas eksperymentów

Linki: [Virtual KITTI 2](#); [RarePlanes](#); [BOP datasets](#); [COCO](#); [Open Images](#); [CLIP](#); [LPIPS](#); [DINOv2](#); [MAST3R](#); [LightGlue](#); [LoFTR](#); [GenBench / CLER](#)

Wspólne wymagania dotyczące repozytorium GitHub

- README.md z celem projektu, instrukcją instalacji, strukturą katalogów, sposobem pobrania/przygotowania danych i sposobem reprodukcji wyników.
- Pliki konfiguracyjne eksperymentów, np. YAML/JSON albo skrypty CLI z jednoznacznymi parametrami.
- Kod treningu, ewaluacji, wizualizacji i generowania danych syntetycznych lub pseudoetykiet.
- Logi, tabele wyników, wykresy oraz przykłady jakościowe w katalogu results/ lub docs/.
- Informacja o wersjach bibliotek, najlepiej requirements.txt, environment.yml albo Dockerfile.
- Krótka sekcja o licencjach użytych danych, modeli i kodu.

Sugerowana punktacja

- 40% - jakość eksperymentów: sensowne punkty odniesienia, badania ablacyjne, metryki, powtarzalność i uczciwe porównania.
- 20% - jakość inżynierska: działający GitHub, reprodukowalne skrypty, dokumentacja, struktura projektu i czytelne konfiguracje.
- 20% - analiza wyników: interpretowalność, mapy uwagi, Grad-CAM, aktywacje, przypadki błędów i dyskusja luki domenowej.
- 20% - raport: jasna struktura, związki z literaturą, opis protokołu, kompletność tabel i wykresów, uczciwe ograniczenia.

Zbiorczy wykaz linków

- [ADE20K](https://ade20k.csail.mit.edu/) - <https://ade20k.csail.mit.edu/>
- [BOP datasets](https://bop.felk.cvut.cz/datasets/) - <https://bop.felk.cvut.cz/datasets/>
- [CLIP](https://github.com/openai/CLIP) - <https://github.com/openai/CLIP>
- [COCO](https://cocodataset.org/) - <https://cocodataset.org/>
- [Cityscapes](https://www.cityscapes-dataset.com/) - <https://www.cityscapes-dataset.com/>
- [ConvNeXt V2](https://github.com/facebookresearch/ConvNeXt-V2) - <https://github.com/facebookresearch/ConvNeXt-V2>
- [D-FINE](https://github.com/Peterande/D-FINE) - <https://github.com/Peterande/D-FINE>
- [DINOv2](https://github.com/facebookresearch/dinov2) - <https://github.com/facebookresearch/dinov2>
- [Detectron2](https://github.com/facebookresearch/detectron2) - <https://github.com/facebookresearch/detectron2>
- [EuroSAT](https://github.com/phelber/eurosat) - <https://github.com/phelber/eurosat>
- [GenBench / CLER](https://github.com/Luodian/GenBench) - <https://github.com/Luodian/GenBench>
- [Google Sheets](https://docs.google.com/spreadsheets/d/1HeEo42INxoAGrou7ehcJk4KBIXR4Gv7RgMd3FmzLE0l/edit?usp=sharing) - <https://docs.google.com/spreadsheets/d/1HeEo42INxoAGrou7ehcJk4KBIXR4Gv7RgMd3FmzLE0l/edit?usp=sharing>
- [LPIPS](https://github.com/richzhang/PerceptualSimilarity) - <https://github.com/richzhang/PerceptualSimilarity>
- [LightGlue](https://github.com/cvg/LightGlue) - <https://github.com/cvg/LightGlue>
- [LoFTR](https://github.com/zju3dv/LoFTR) - <https://github.com/zju3dv/LoFTR>
- [MAE](https://github.com/facebookresearch/mae) - <https://github.com/facebookresearch/mae>
- [MASt3R](https://github.com/naver/mast3r) - <https://github.com/naver/mast3r>
- [Open Images](https://storage.googleapis.com/openimages/web/index.html) - <https://storage.googleapis.com/openimages/web/index.html>
- [Oxford-IIIT Pets](https://www.robots.ox.ac.uk/~vgg/data/pets/) - <https://www.robots.ox.ac.uk/~vgg/data/pets/>
- [RT-DETRv2](https://github.com/lyuwenyu/RT-DETR) - <https://github.com/lyuwenyu/RT-DETR>
- [RarePlanes](https://www.iqt.org/library/the-rareplanes-dataset) - <https://www.iqt.org/library/the-rareplanes-dataset>
- [RarePlanes GitHub](https://github.com/VisionSystemsInc/RarePlanes) - <https://github.com/VisionSystemsInc/RarePlanes>
- [SAM 2](https://github.com/facebookresearch/sam2) - <https://github.com/facebookresearch/sam2>
- [SegFormer](https://github.com/NVlabs/SegFormer) - <https://github.com/NVlabs/SegFormer>
- [T-LESS toolkit](https://github.com/thodan/t-less_toolkit) - https://github.com/thodan/t-less_toolkit
- [Unity SynthDet](https://github.com/Unity-Technologies/SynthDet) - <https://github.com/Unity-Technologies/SynthDet>
- [Virtual KITTI 2](https://europe.naverlabs.com/proxy-virtual-worlds-vkitti-2/) - <https://europe.naverlabs.com/proxy-virtual-worlds-vkitti-2/>
- [YOLOv10](https://github.com/THU-MIG/yolov10) - <https://github.com/THU-MIG/yolov10>
- [pytorch-grad-cam](https://github.com/jacobgil/pytorch-grad-cam) - <https://github.com/jacobgil/pytorch-grad-cam>
- [xView](https://xviewdataset.org/) - <https://xviewdataset.org/>

